7. Multi-head

Mỗi head ~~sa~~ học & trích xuất thông tin ở 1 kgian con độc lập có chiều $d_k - d / h$ Việc phép nối giúp gom toàn bộ thông tin model từ tất cả các head về lại kthể c đầy đủ bđầu, nhờ đó phép nhân tuyến tính mới có thể pha trộn, tổng hợp chéo đặc trưng giữa các head ≠ nhau.

11. Experiment 1

Nếu chỉ dùng self-attention mà ko có PE phép biến đổi là tg đương hoán vị: khi đổi chỗ các từ đầu vào, các vector đầu ra chỉ đổi chỗ tương ứng chứ giá trị ko đổi. Sau khi lấy tb vector đại diện ở 2 câu đảo ngược ngữ nghĩa khiến mô h ko thể pbt chủ s tân ngữ

CRABIT

15.

Nếu dùng F(x) toàn bộ thông tin gốc x phải đi qua các phép biến đổi phức tạp dễ mất mát đặc trưng ban đầu. Sử dụng x + F(x) tạo đg truyền tốt cho phép giữ thông tin gốc, giúp mô hình chỉ cần học phần hiệu chỉnh.

19. Experiment 2

- Ko. Tổng c̉ biểu diễn $d_{model} = 128$; tổng số tham số c̉ mô h. giữ ng ko đổi ở ∀ cấu h. head.
- Chiều c̉ mỗi head ↓ tỷ lệ nghịch theo công thức. Vc chia thành 2 or 4 giúp mô h. học đc nh góc nhìn ghè hơn nhg chia quá nhỏ lm dung lg biểu diễn c̉ từng kgian con bị thu hẹp.

20 Experiment 3

Multi-head attention () thực nơi có tạo ra các sắc thái phổ (:) số ≠ nhau nhg ch phân tách thành các quy tắc hoàn toàn độc lập mà vẫn htv chung vào các từ khoá cxúc chính.

/

21. Experiment 4

- tg tác trực tiếp & Mean pooling vs Last hidden state: LSTM nén toàn bộ chuỗi qua từng bước tgian vào vector ẩn cuối cx dễ bị rơi rụng thông tin ở đầu câu dài. Self-attention kết hợp mean pooling ở transformer cho phép mọi token tg tác trực tiếp với nhau với k/c $O(1)$

22. Experiment 5

Dù tăng sequence length giúp giữ lại nh nội dung đánh giá hơn & đẩy F1 tăng mạnh nhg kích thc mtrận attention tăng theo bậc 2 $O(n^2)$

25. Experiment 6.

Cách lấy sequence representation có ảnh hg rõ rệt tới hành vi phân loại. Mean pooling lấy tb đều ∀ token hợp lệ nên đạt độ cxác tổng thể ~~cân~~ & precision cân = hơn. CLS pooling thiên về bắt tín hiệu tích cực mạnh.